

Evaluation AI

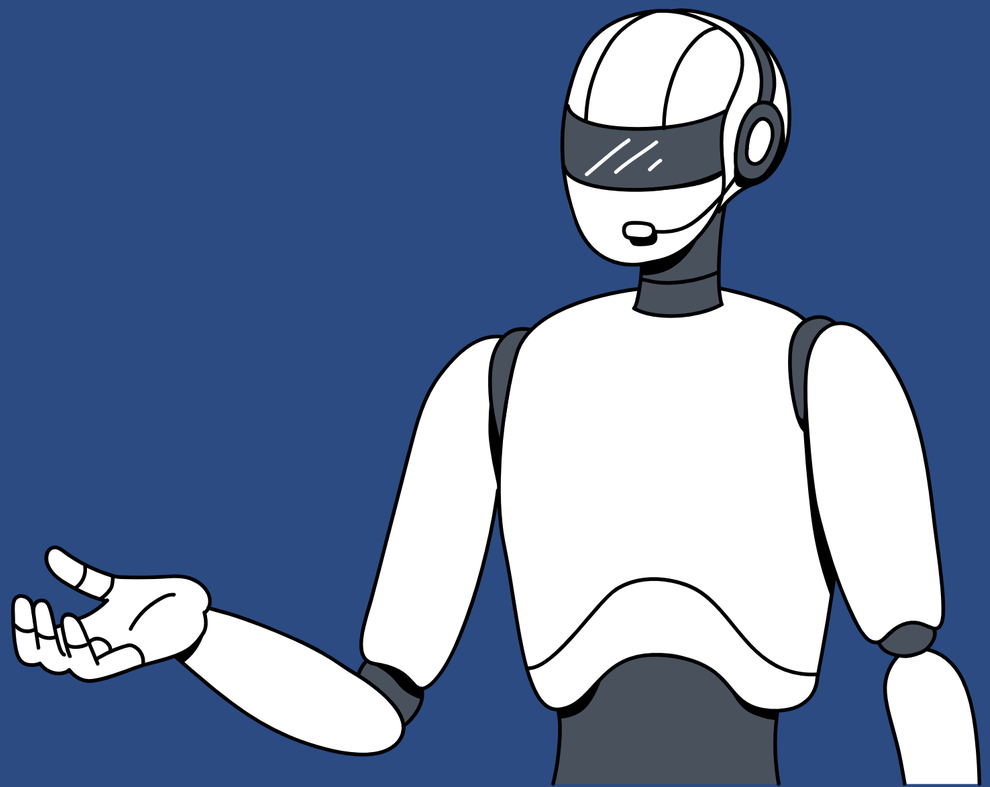
Оценка дискриминативных моделей

Автор курса Мешков Александр

Лекция 2: Evaluation ML/DL

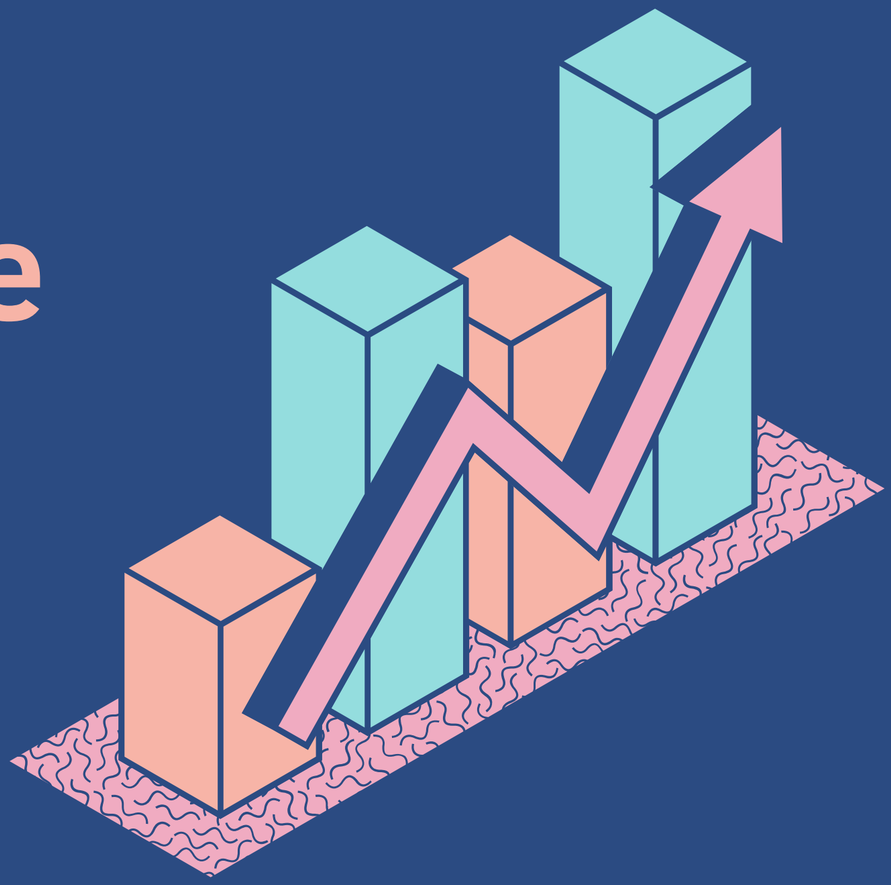
ПЛАН ЛЕКЦИИ:

1. Дискриминативные модели
2. Что такое нейросети и глубокое обучение
3. Работа с данными
4. Confusion Matrix
5. Классические метрики для классификации
6. Классические метрики для регрессии
7. Функции потерь



Дискриминативные модели

ДАЮТ ОТВЕТ С ОПРЕДЕЛЕННОЙ ДОЛЕЙ ВЕРОЯТНОСТИ



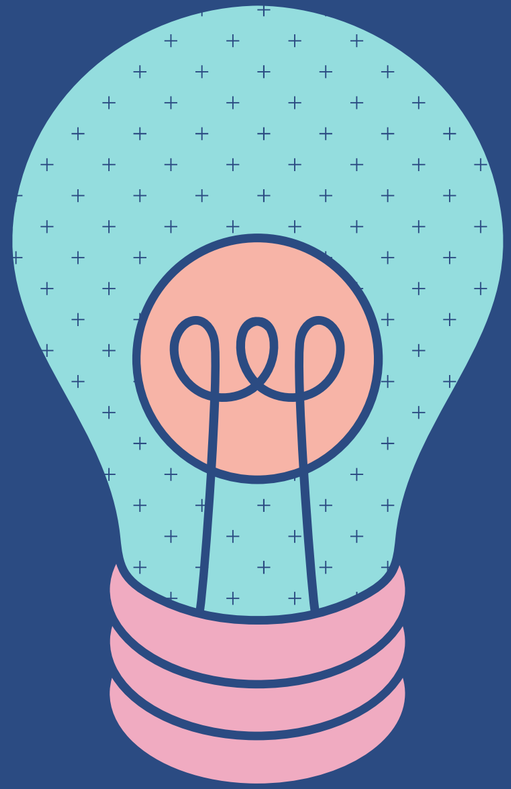
Нейронные сети - модели, вдохновленные работой мозга

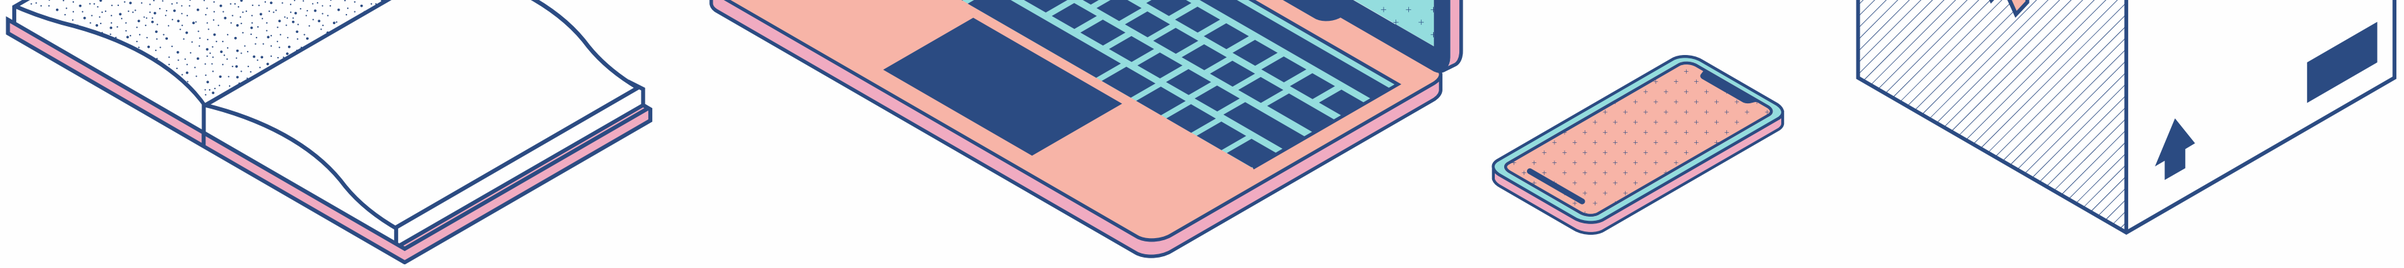
Глубокое обучение - нейросети с множеством слоев (>3)

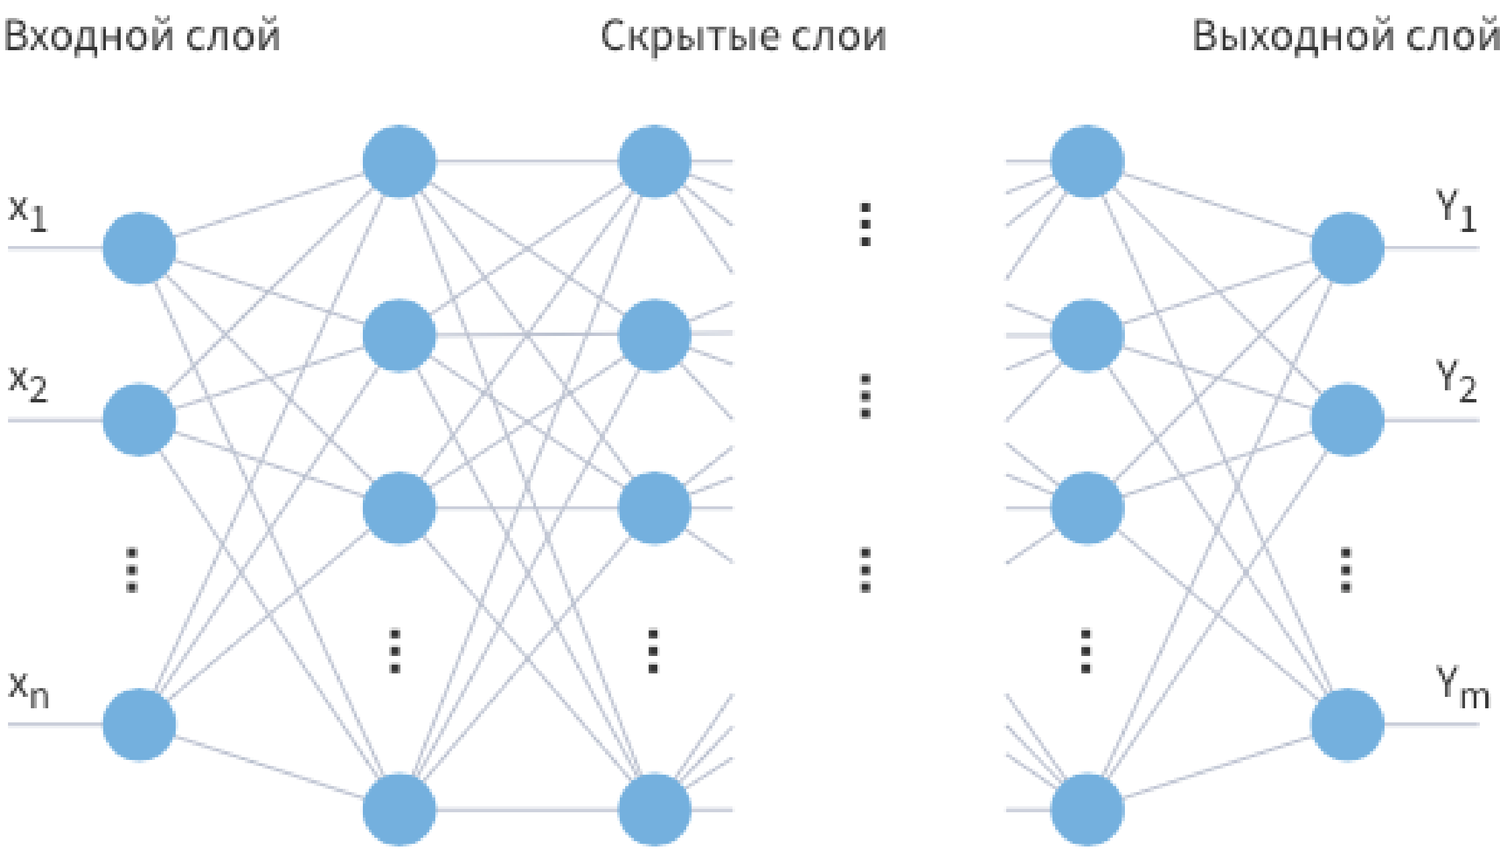
Ключевые компоненты:

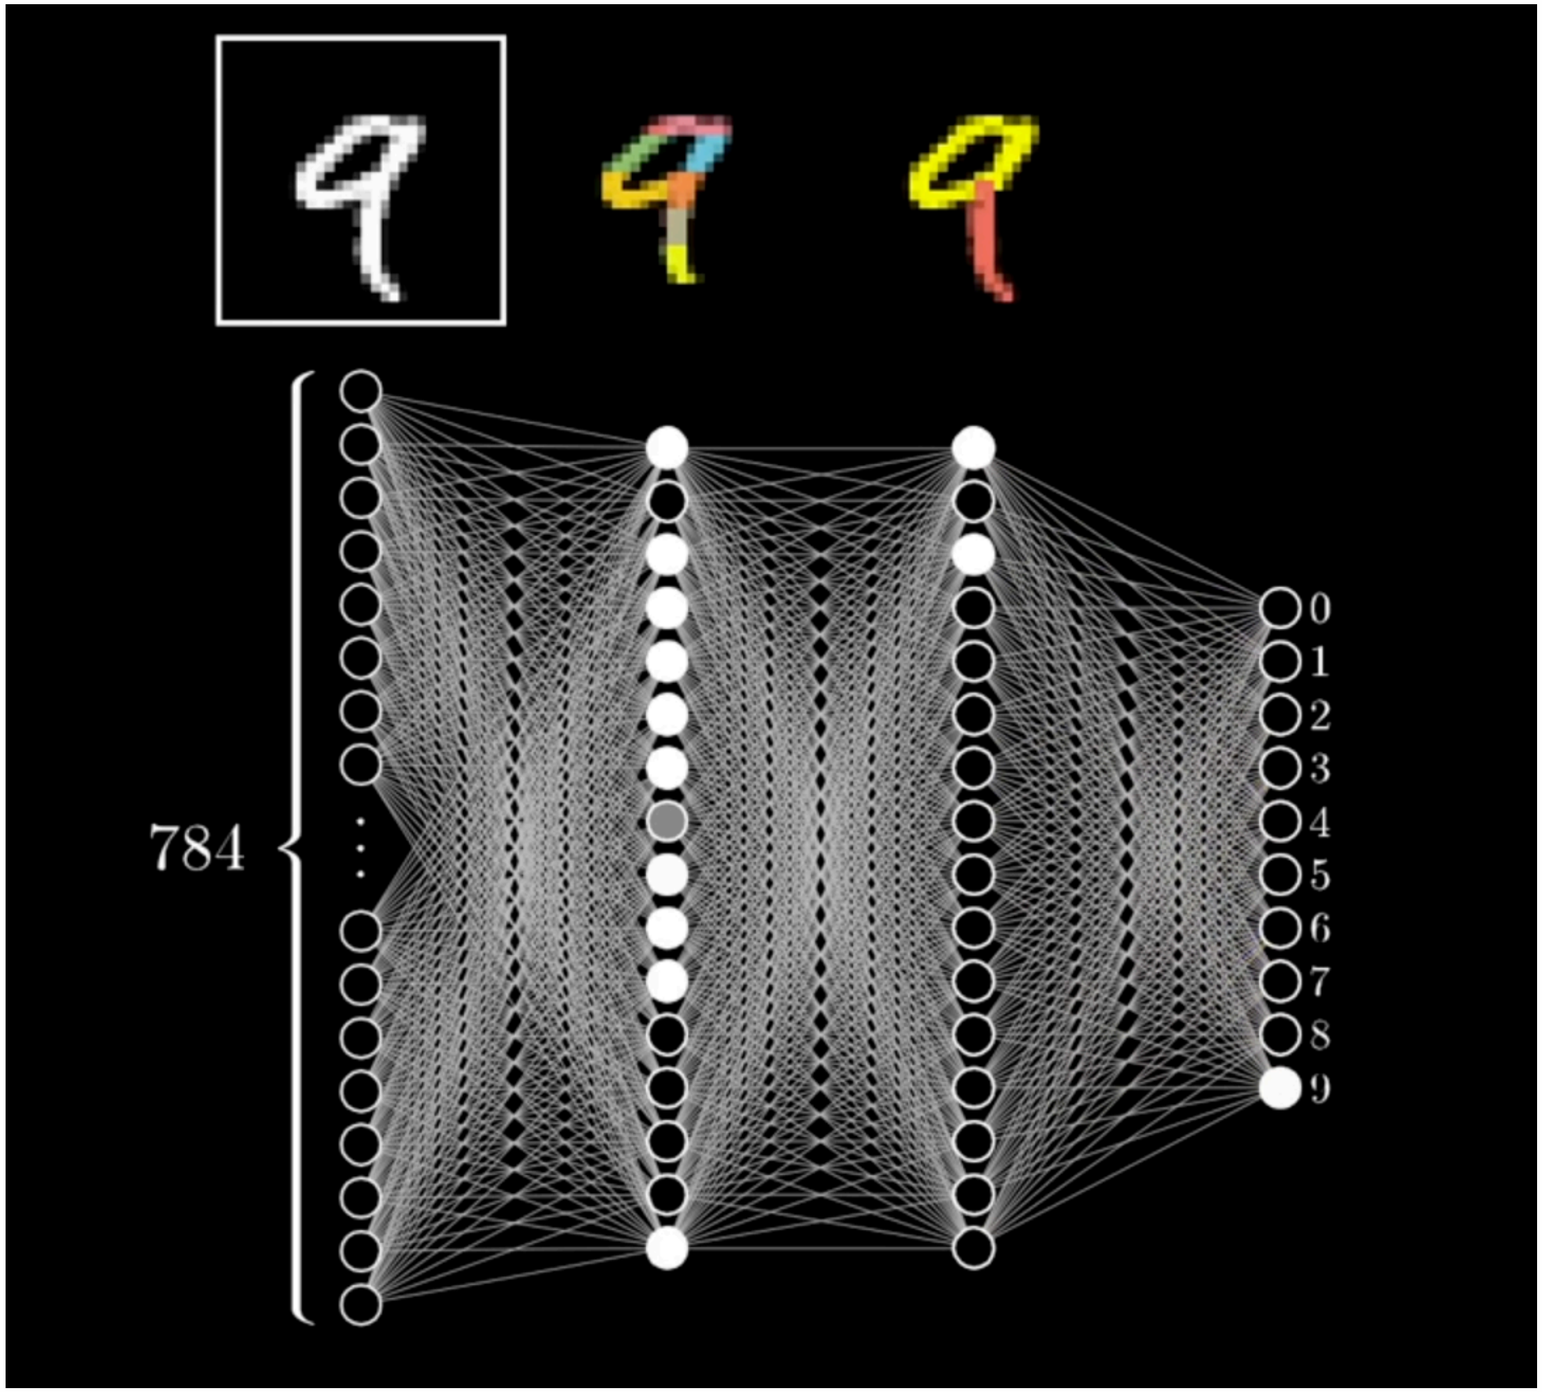
- Слои нейронов с весами и активациями
- Функции активации (ReLU, Sigmoid, Tanh)
- Обратное распространение ошибки

Применение: компьютерное зрение, NLP, рекомендательные системы






Входной слой
Скрытые слои
Выходной слой
x_1
x_2
x_n
Y_1
Y_2
Y_m


784
0
1
2
3
4
5
6
7
8
9

Основные архитектуры глубокого обучения

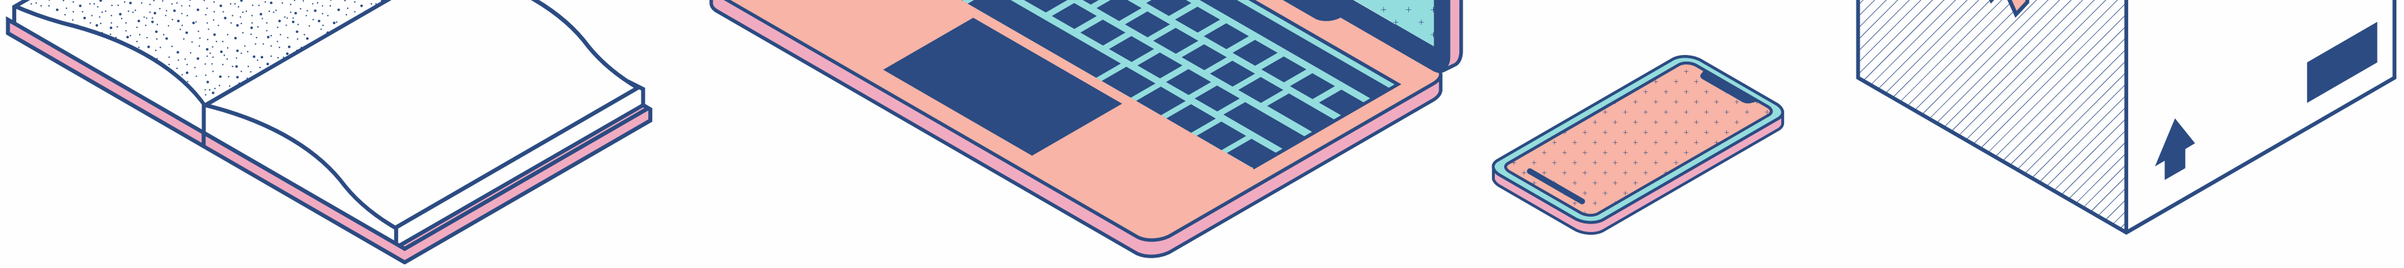


Принцип разделения данных



!!!Test set используется ТОЛЬКО ОДИН РАЗ!

Важно! Это фундаментальный принцип машинного обучения.
Training set — это "учебник" для модели.
Validation set — это "домашние задания", на которых мы проверяем, как модель усваивает материал и корректируем подход.
Test set — это "экзамен", который должен проходиться только один раз.



КЛАССИФИКАЦИЯ (категории)

Примеры результатов:

- "больной" или "здоровый"
- "спам" или "не спам"
- "кот", "собака", "птица"
- "удовлетворен/неудовлетв."

РЕГРЕССИЯ (числа)

Примеры результатов:

- Цена: $45,230.50
- Возраст: 27.3 года
- Температура: 23.7°C
- Задержка: 12.5 минут

Confusion Matrix

ОСНОВА МЕТРИК КЛАССИФИКАЦИИ



	ACTUALLY POSITIVE (1)	ACTUALLY NEGATIVE (0)
PREDICTED POSITIVE (1)	True Positives (TP)	False Positives (FP)
PREDICTED NEGATIVE (0)	False Negative (FN)	True Negative (TN)

TP (True Positive) — правильно предсказанные положительные
TN (True Negative) — правильно предсказанные отрицательные
FP (False Positive) — ложные срабатывания (Type I error)
FN (False Negative) — пропуски (Type II error)

Confusion Matrix

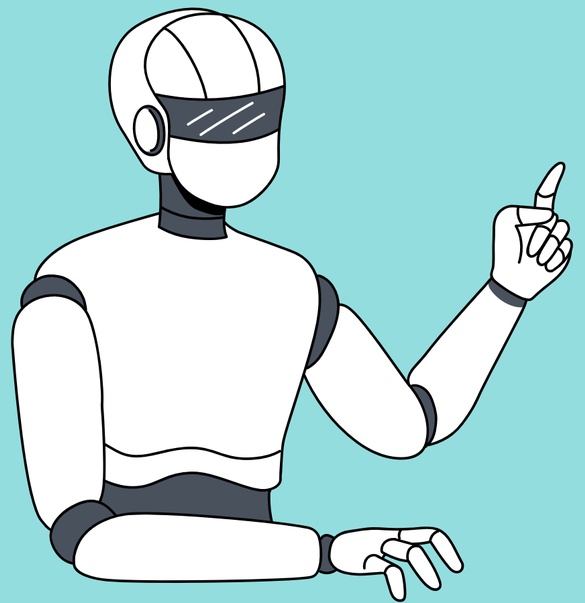


ПРИМЕР 1: EMAIL КЛАССИФИКАЦИЯ

Данные: 1000 писем
Реальность: 200 спам, 800 не спам
Предсказания модели: 180 спам, 820 не спам

	ACTUALLY POSITIVE (200 СПАМ)	ACTUALLY NEGATIVE (800 НЕ СПАМ)
PREDICTED POSITIVE (180 СПАМ)	TP - 150 (правильно найденный спам)	FP = 30 (обычные письма, помеченные как спам)
PREDICTED NEGATIVE (820 НЕ СПАМ)	FN = 50 (пропущенный спам)	TN = 770 (правильно пропущенные обычные письма)

Базовые метрики оценки ML



Accuracy = (TP + TN) / (TP + TN + FP + FN)
Показывает долю правильных предсказаний

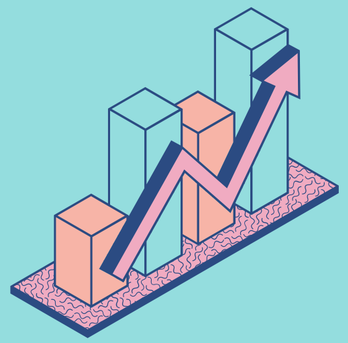
Precision = TP / (TP + FP)
Precision отвечает на вопрос: "Насколько мы можем доверять положительным предсказаниям модели?" Высокий precision означает, что когда модель говорит "да", она обычно права.

Recall = TP / (TP + FN)
Recall отвечает на вопрос: "Насколько хорошо мы находим то, что ищем?" Высокий recall означает, что мы пропускаем мало важных случаев.

F1-Score = 2 × (Precision × Recall) / (Precision + Recall)
F1-Score — компромиссная метрика, которая штрафует модели с очень низким precision или recall.
Максимальное значение: 1.0 (идеальная модель) Минимальное значение: 0.0 (худшая модель)

F-beta Score

Настраиваемый баланс



F-beta Score (F_β) = $(1 + \beta^2) \times (\text{Precision} \times \text{Recall}) / (\beta^2 \times \text{Precision} + \text{Recall})$

- F0.5: β=0.5, больше внимания precision. Используется когда ложные срабатывания дороже пропусков (рекламные системы, премиум рекомендации)
- F1: β=1, равный баланс. Универсальная метрика для большинства задач
- F2: β=2, больше внимания recall. Используется когда пропуски критичнее ложных срабатываний (медицина, безопасность)

Специфичные метрики классификации для нейросетей

Softmax outputs: вероятностные предсказания

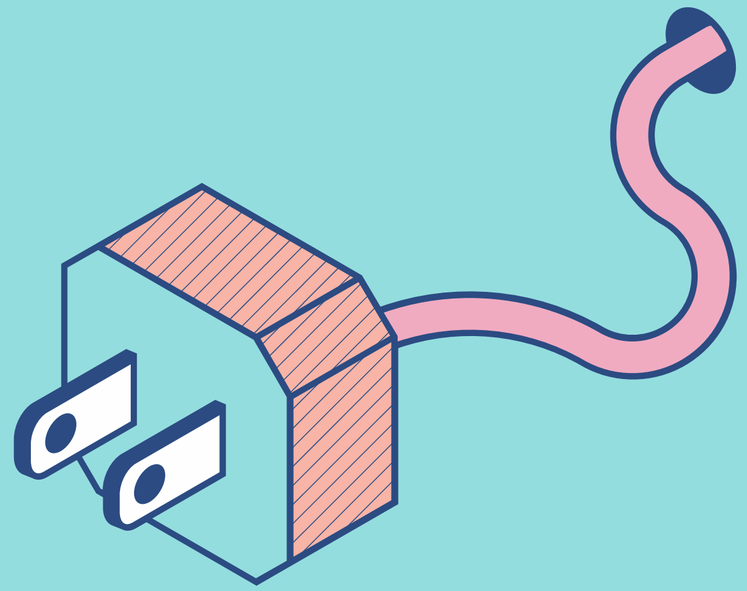
Confidence scores: max(softmax_output)

Top-k accuracy: правильный класс в топ-k предсказаниях

- Top-1: обычная accuracy
- Top-5: часто используется для ImageNet

Calibration: соответствие confidence реальной точности

Entropy: $H = -\sum p_i \log(p_i)$ для измерения неопределенности



R-squared

$R^2 = 1 - (SS_RES/SS_TOT)$

SS_TOT (TOTAL SUM OF SQUARES) — ОБЩАЯ ВАРИАТИВНОСТЬ ДАННЫХ

SS_RES (RESIDUAL SUM OF SQUARES) — НЕОБЪЯСНЕННАЯ ВАРИАТИВНОСТЬ

Интерпретация значений R^2

$R^2 = 1.0$ (идеальная модель)

- SS_res = 0 — модель делает идеальные предсказания
- Все точки лежат точно на линии регрессии
- В реальности почти невозможно — может указывать на overfitting или data leakage

---

$R^2 = 0.0$ (модель = среднее значение)

- SS_res = SS_tot — ошибки модели равны ошибкам простого среднего
- Модель не использует признаки, всегда предсказывает среднее
- Бесполезная модель — можно заменить константой

$R^2 < 0$ (модель хуже среднего)

- SS_res > SS_tot — модель делает предсказания хуже, чем просто среднее значение
- Что-то пошло не так: переобучение, плохие признаки, ошибки в коде
- Лучше использовать константу вместо такой модели

ПРОГНОЗИРОВАНИЕ ЦЕН НЕДВИЖИМОСТИ

Данные: 1000 домов, цены от $200K до $800K
Среднее значение: $500K

Простая модель (все дома стоят одинаково $500K):
Реальность: Дом А = $300K, Дом Б = $700K, Дом В = $450K
Среднее = $y=(300+700+450)/3=1450/3 = 483.33$

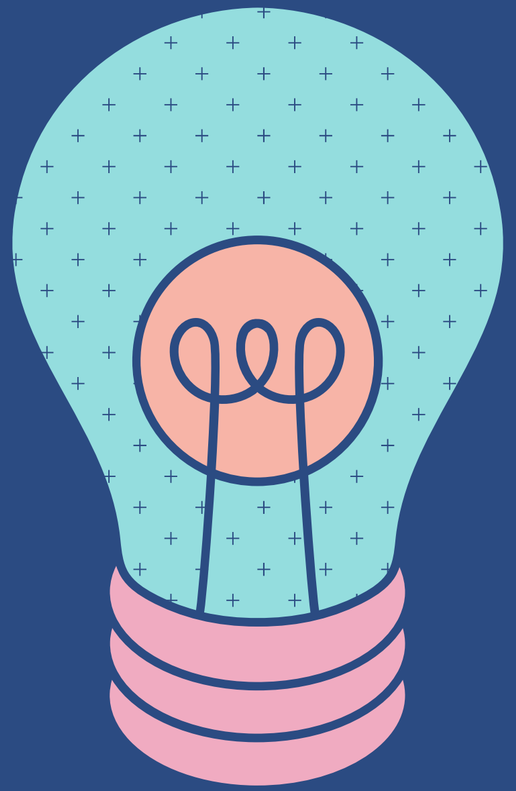
SS_tot = сумма всех квадратов отклонений от среднего = 81,666.67

SS_res=сумма всех квадратов отклонений от предсказаний=40,000+40,000+2,500=82,500

R2 = 1 - (SS_res / SS_tot) = 1- (82500/81666,67)= -0,0102

Модель с признаками (цена зависит от площади, района и года):
Ваши предсказания:

- Дом А (50м², старый район): $320K (реально $300K)
- Дом Б (150м², центр): $680K (реально $700K)
- Дом В (90м², средний район): $470K (реально $450K)

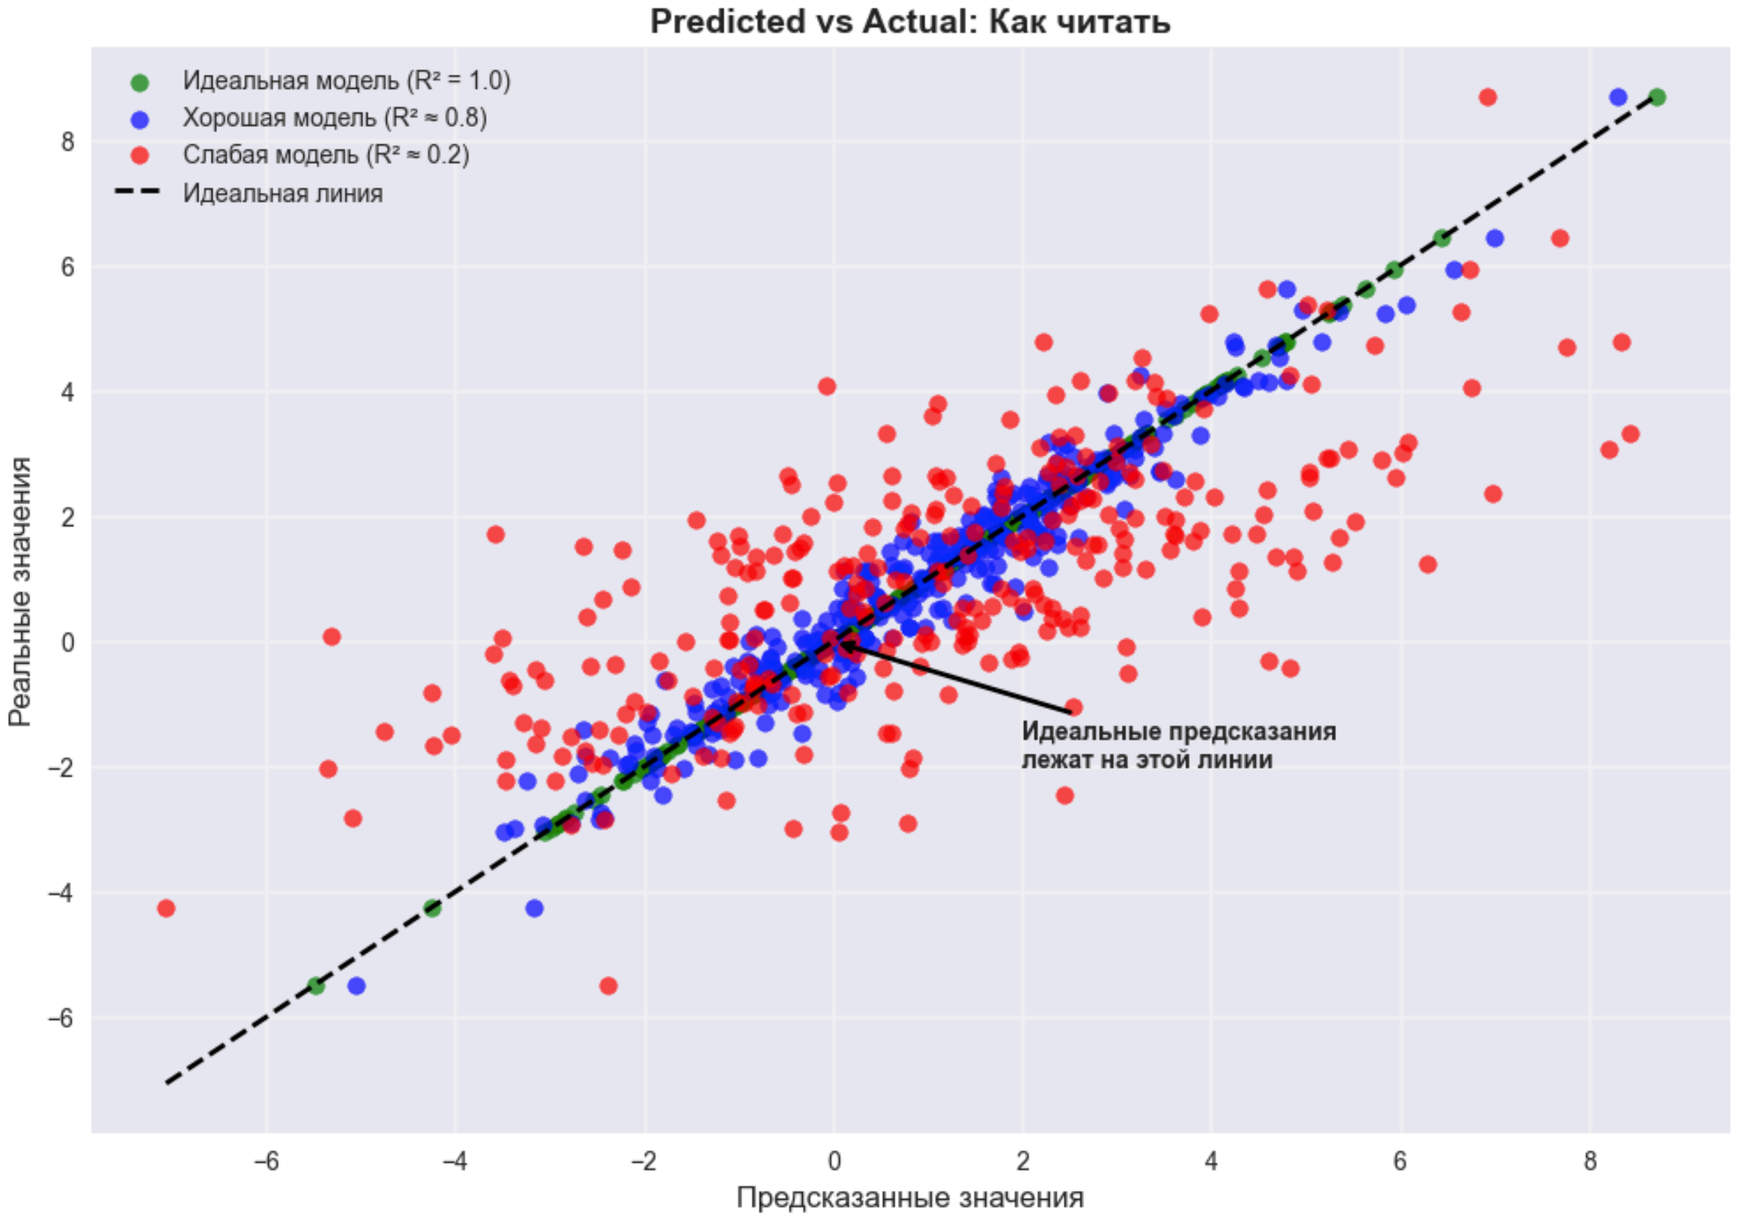


Предсказания близки к реальным ценам

Ошибки намного меньше! SS_res = сумма квадратов отклонений от предсказаний = 400+400+400 = 1200

$R^2 = 1- (1200/81666,67)=0,9853$

Интерпретация: Площадь, район и год постройки объясняют 98% различий в ценах домов


Predicted vs Actual: Как читать
Идеальная модель (R² = 1.0)
Хорошая модель (R² ≈ 0.8)
Слабая модель (R² ≈ 0.2)
Идеальная линия
Идеальные предсказания
лежат на этой линии
Реальные значения
Предсказанные значения
8
6
4
2
0
−2
−4
−6
−6
−4
−2
0
2
4
6
8

MAE (Mean Absolute Error)

"В среднем наша модель ошибается на столько то при предсказании"

Наши предсказания vs реальность:
Дом 1: предсказали $480K, реально $500K → ошибка $20K
Дом 2: предсказали $320K, реально $300K → ошибка $20K
Дом 3: предсказали $675K, реально $700K → ошибка $25K
Дом 4: предсказали $420K, реально $450K → ошибка $30K

Средняя ошибка = ($20K + $20K + $25K+ $30K) / 4 = $23,75K

RMSE (Root Mean Square Error)

"Учитывает большие промахи"

RMSE больше MAE → значит есть случаи с большими ошибками
Например:
Дом 5: предсказали $400K, реально $600K → ошибка $200K!

Как считается
Шаг 1: Возводим каждую ошибку в квадрат
Шаг 2: Складываем квадраты
Шаг 3: Находим среднее
Шаг 4: Извлекаем корень

RMSE = √8,465,000,000 ≈ $92K

Функции потерь как метрики evaluation

Cross-entropy loss для классификации:

- $L = -\sum y_i \log(p_i)$
- Отражает качество вероятностных предсказаний

Mean Squared Error для регрессии:

- $MSE = 1/n \sum(y_{true} - y_{pred})^2$

Custom losses для специфических задач:

- Dice loss для сегментации
- Triplet loss для embedding learning
- Focal loss для несбалансированных данных

Обнаружение переобучения (overfitting detection)

Что такое переобучение? Модель "запоминает" обучающие данные вместо изучения общих закономерностей

Кривые обучения — главный инструмент диагностики

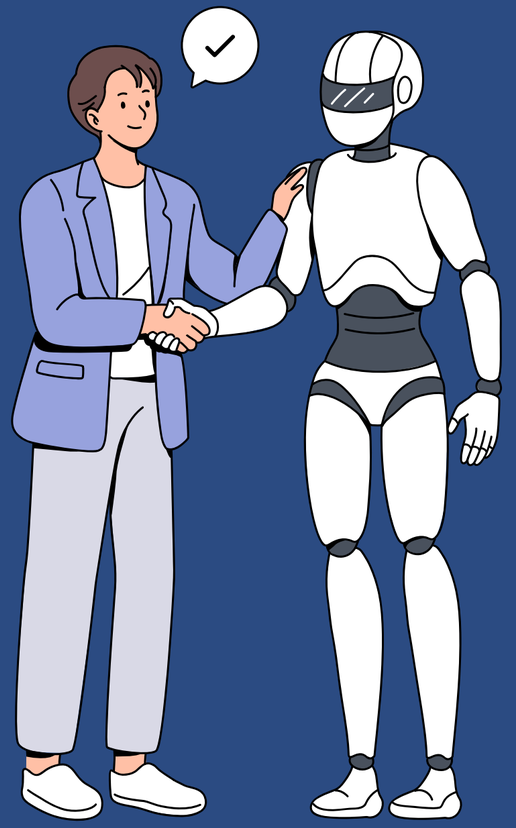
- График потерь на train/validation данных по эпохам
- Показывает динамику обучения в реальном времени

Признаки переобучения:

- Training loss падает ↓, validation loss растет ↑
- Большой разрыв между train и validation точностью
- Нестабильность метрик на validation

Решения:

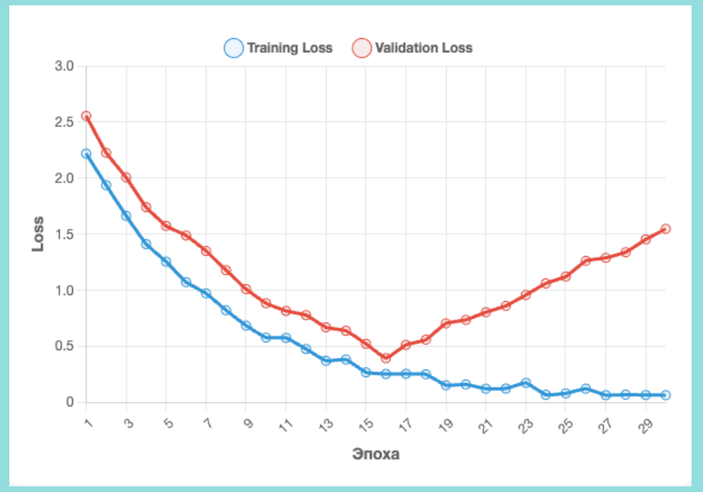
- Early stopping — остановка при ухудшении validation
- Регуляризация — L1/L2, dropout, batch norm
- Мониторинг влияния регуляризации на обобщение



Примеры переобучения

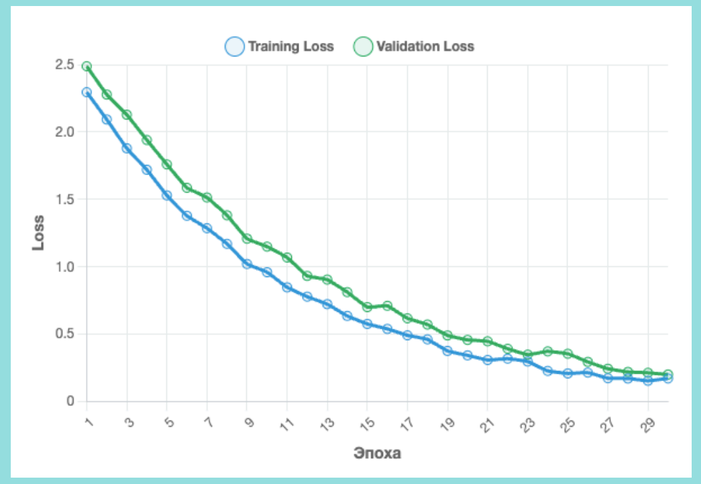
Классическое переобучение

Признаки: Training loss продолжает падать, validation loss начинает расти после 15-й эпохи. Большой разрыв между кривыми.



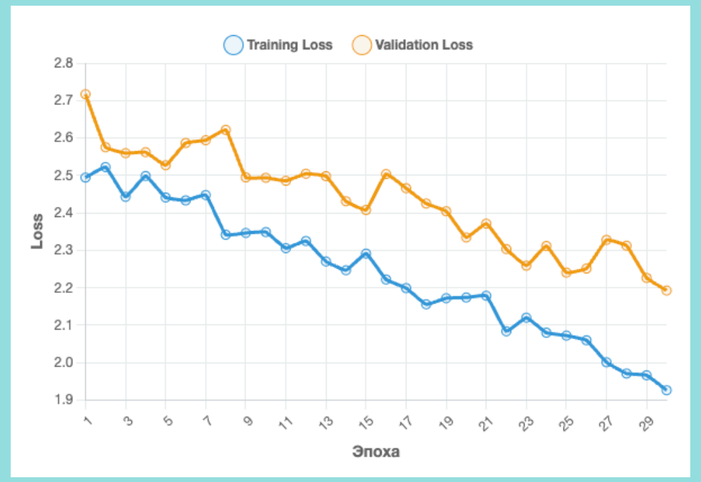
Хорошее обучение

Идеал: Обе кривые снижаются синхронно и стабилизируются. Небольшой разрыв между train и validation - это нормально.



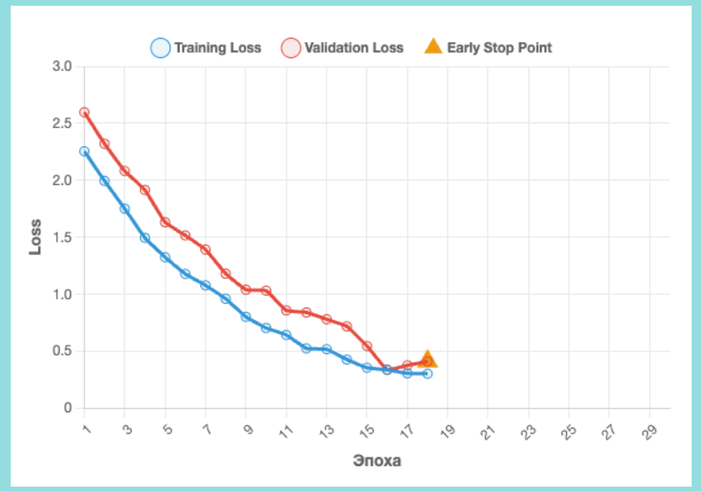
Недообучение

Проблема: Обе кривые остаются высокими и не улучшаются. Модель слишком простая для данных.



Early Stopping в действии

Решение: Обучение остановлено на 18-й эпохе, когда validation loss начал расти. Модель откатилась к лучшему состоянию.



⚠️ Важно: Переобучение начинается, когда validation loss перестает улучшаться или начинает расти, в то время как training loss продолжает падать.

Оценка вычислительной эффективности моделей

Вычислительная эффективность

- FLOPs (Floating Point Operations): алгоритмическая сложность модели
- Количество параметров: влияет на memory usage
- Время inference: реальное время предсказания
- Memory consumption: использование GPU/CPU
- Energy efficiency: потребление энергии
- Throughput: количество примеров в секунду

Как выбрать лучшую модель

Для классификации:

- Accuracy — основная метрика (% правильных ответов)
- Top-5 accuracy — для задач с большим количеством классов
- Confidence scores — насколько модель уверена в ответах
- Cross-entropy loss — чем меньше, тем лучше

Для регрессии:

- **MAE — средняя ошибка (легко понять)**
- **RMSE — если большие ошибки критичны**
- **R^2 — какую долю данных объясняет модель**
- **MSE** - чем меньше, тем лучше

Дополнительные факторы:

- **Время inference — скорость работы модели**
- **Размер модели — сколько памяти занимает**
- **Стабильность — одинаковые ли результаты при повторах**

Правило 5 запусков — идеал, но в реальности часто делают 1 запуск из-за стоимости.
Что происходит при каждом запуске:

1. Новая случайная инициализация весов
2. Новое случайное перемешивание training данных
3. Полное обучение модели с нуля
4. Тестирование на том же validation датасете

Только после лучший вариант тестируется на test set!

ОЦЕНКА СПОСОБНОСТИ К ОБОБЩЕНИЮ (GENERALIZATION EVALUATION)

Train-test gap: разница в качестве между обучением и тестом

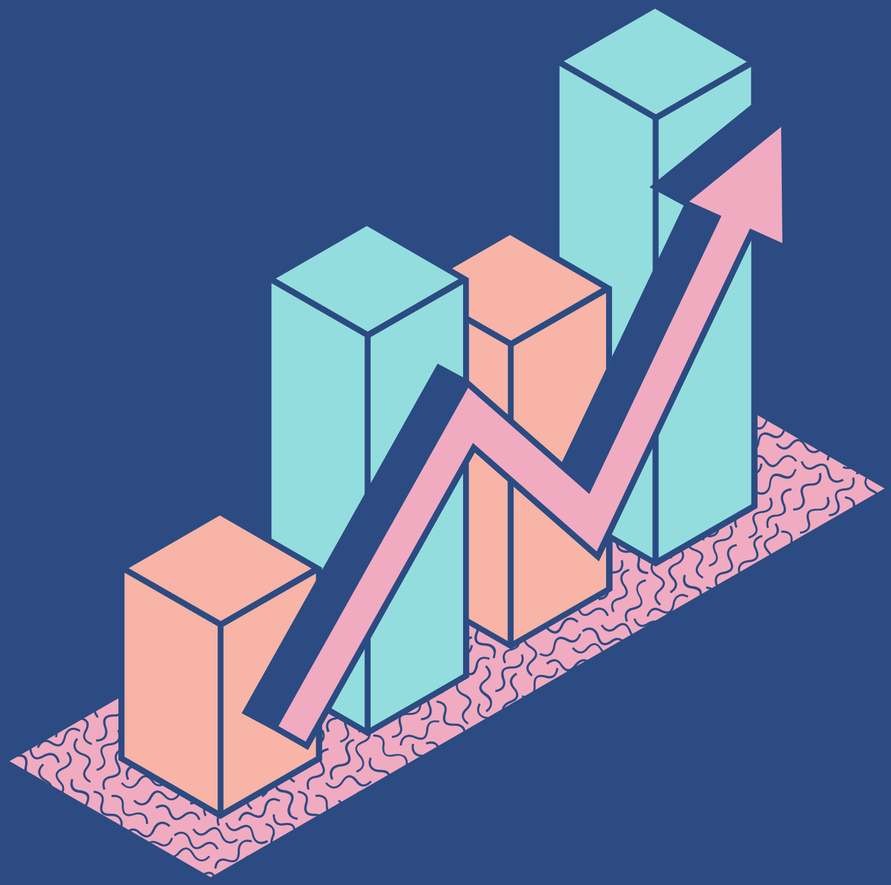
Distribution shift: когда реальный мир не соответствует лаборатории

- Covariate shift: изменение входных данных
- Concept drift: изменение целевой переменной

Domain adaptation: проверка универсальности модели

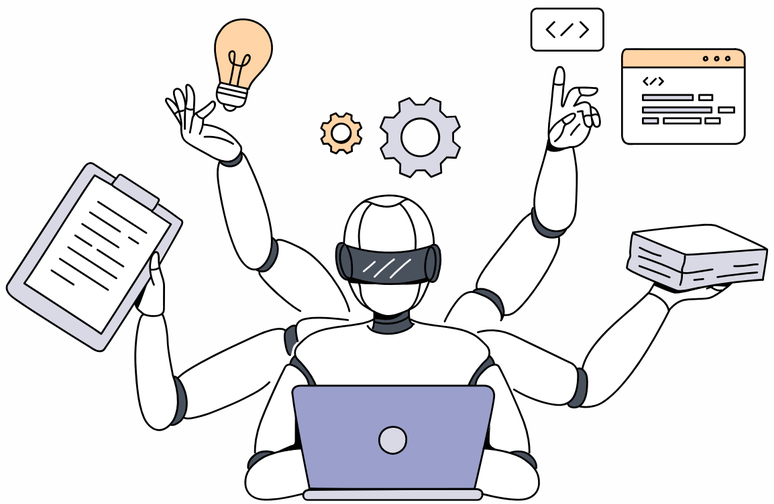
Out-of-distribution detection: когда модель встречает неизвестное

Robustness evaluation: проверка стабильности к возмущениям



Практика

Метрики классификации в машинном обучении



Наши цели

- Разобраться в базовых принципах работы с датасетом в рамках ML
- Изучить разные методы ML
- Обучить небольшую модель
- Изучить и применить на практике основные метрики оценки качества классификации и регрессии.

Делаем самостоятельно

Практика 1.

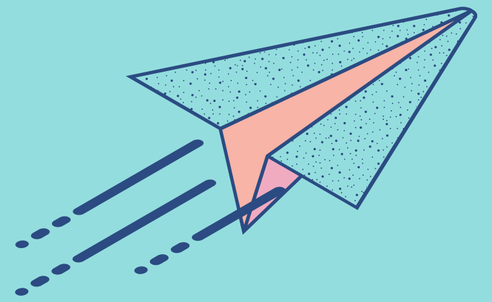
- Создаем модели методами Random Forest, KNeighborsClassifier, Logistic Regression для своего датасета и сравните результаты оценки

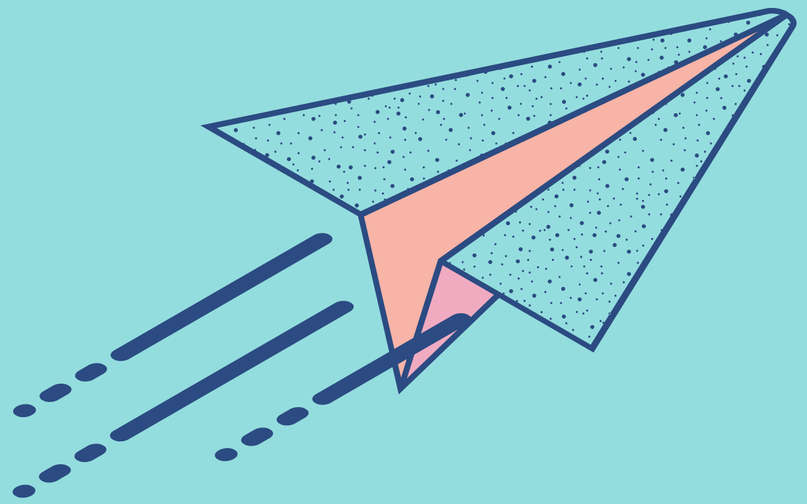
Практика 2.

- Выполнить оценку метрик R-squared, RMSE, MAE для модели регрессии для любого датасета.



Делаем самостоятельно



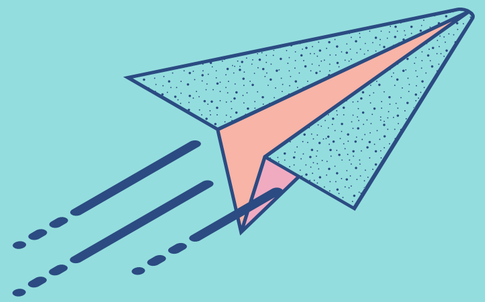


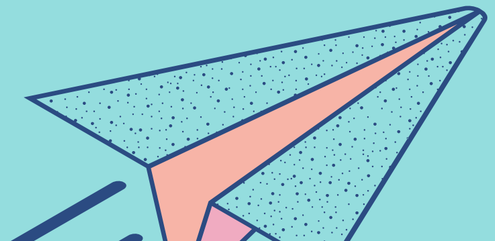
Практика 3.

- Выполните глубокое обучение на основе датасета diamonds и оцените качество полученной регрессионной модели
- По желанию: Измените параметры layers.Dense и посмотрите, как измениться качество.

Практика 4.

- Выполните глубокое обучение на датасете MNIST, используя пример с CIFAR-10 и новые архитектуры моделей, определите особенности каждой архитектуры и лучшую из них.





Где скачать датасеты

Источники готовых датасетов для машинного обучения

Kaggle (самый популярный)
Сайт: kaggle.com/datasets

Популярные датасеты:

- Titanic (для начинающих)
- House Prices
- Credit Card Fraud Detection
- COVID-19 данные

UCI Machine Learning Repository
Сайт: archive.ics.uci.edu/ml

Популярные датасеты:

- Iris (цветы ириса)
- Wine Quality
- Adult Census Income
- Breast Cancer Wisconsin

Scikit-learn встроенные датасеты

Популярные встроенные датасеты:
load_iris() *# Классификация цветов*
load_breast_cancer() *# Диагностика рака*
load_wine() *# Классификация вин*
oad_digits() *# Распознавание цифр*
load_boston() *# Цены на недвижимость*
make_classification() *# Генерация искусственных данных*

На сегодня это все!

Вопросы?

